

Epistemische Fallstudie — Befunde mit Daten


Die „epistemische Validierung“ eines Muse-Spark-1.1-Textes durch MarCognition-AI, analysiert mit DESi

Quelle: Hugging-Face-Beitrag „*Epistemic Stress Test — Muse Spark 1.1 validated by MarCognition-AI*“ (User elly99, 2026-07-10; Zenodo 10.5281/zenodo.20509721) und github.com/elly99-AI/MarCognition-AI. Regeneriert offline & deterministisch mit `python -m desi.case_studies.marcognition_muse_spark`. Jede Zahl unten stammt aus `summary.json` / `claims.jsonl` / `evidence.jsonl`.

23 atomare Claims typisiert & verankert	4/23 Claims mit domänen- zulässiger Evidenz	3 strukturelle Wider- sprüche (Detektor)	ja selbstabdeichender Schluss; Falsifier: nein
---	---	--	--

Verteilung der Urteile (23 Claims)

Keine binären VERIFIED/FAILURE-Stempel: Heuristiken, Interpretationen und normative Aussagen bekommen eigene Kategorien; „unverifiable“ ist ein erstklassiges Urteil, keine Notlösung.



Evidenzstärke — wo konkrete Belege fehlen



18 von 23 Claims haben gar keine konkrete Evidenzpassage — der Validator nannte durchweg „das PubMed-Dokument“ ohne Titel oder Fundstelle. (Audit R4: diese Zahlen beschreiben die bereitgestellte Evidenz über 23 kuratierte Claims, keine gemessene Fundierung des Muse-Textes.)

Drei strukturelle Konflikte

Gefunden von DESis eigenem Detektor `desi.self_audit.contradictions.find_contradictions` als Schlüssel/Wert-Inkonsistenzen — nicht von Prosa behauptet. Nicht jeder ist ein logischer Widerspruch; die „Art“ hält die Stärke fest.

C1 — Logischer Widerspruch: Prompt ↔ Methode

Die Methode (muse:L206): „No epistemic instructions (verification, sources, stages)“. Der abgedruckte Prompt verlangt ≥5 Quellen mit Direktzitaten (L56–58), eine Zitationskonsistenzprüfung (L64) und sechs benannte Phasen (L29–47). Ein echter Widerspruch: beide Aussagen können nicht zugleich wahr sein. (Audit-Vorbehalt R1: der Prompt-Titel muse:L12 nennt „prompt used on chatgpt (taken from marcognity)“ — Herkunft leicht unklar; der Widerspruch hält auf den eigenen Angaben der Methode.)

C2 — Pipeline-Inkonsistenz: VERIFIED ohne zitierbare Evidenz

„VERIFIED“ und „No citations found“ können theoretisch beide zutreffen — kein strikter logischer Widerspruch. Der eigentliche Fehler: der Skeptical Agent behauptet Quellenunterstützung (L170–198), nennt aber keine Quelle und keine Passage (nur „das PubMed-Dokument“); der Citation Checker findet zugleich keine überprüfbaren Referenzen (L201–202) — obwohl der Text acht trägt (L154–161). Beide werden ohne Konsistenzprüfung zusammengefügt (agent_metacognition L48–66).

C3 — Unbelegte Unabhängigkeit: „independent“ ↔ keine dokumentierte Unabhängigkeit

Dass der Validator technisch ein einzelnes `llm.invoke` ist (skeptical_agent L62), widerlegt Unabhängigkeit nicht per se — ein externer LLM-Aufruf könnte formal unabhängig sein. Der Konflikt ist enger: „independent external validation“ (L208) wird behauptet, ohne dass auf irgendeiner Achse Unabhängigkeit dokumentiert wäre — organisatorisch, modellseitig oder evidenzseitig. Der Validator erhält genau die Generierungsdokumente (evaluator_prompt L24–28), ist nicht adversarial und nicht reproduzierbar spezifiziert. Behauptet, nicht etabliert — eine methodische Fehlklassifikation.

Selbstabdichtung & Falsifizierbarkeit

Würde stützen	Validator markiert Unverifizierbares → Lücke sichtbar; ODER Validator scheitert → Boundary „im Validator selbst“ (L237). Beide Ausgänge bestätigen.
Würde schwächen	Ein vorregistrierter Lauf, in dem der Validator mit domänenkorrekten Quellen Claims mit zitierten Passagen bestätigt — nicht bereitgestellt.
Würde widerlegen	Eine Kontrolle, in der die Residualfehler unter sauberem Source-Gating verschwinden (Pipeline-Defekt statt „intrinsische Architektur“) — nicht bereitgestellt.
Falsifikationsbedingung im Versuch?	Nein. Da Erfolg und Versagen beide bestätigen und kein Ausgang als widerlegend benannt ist, ist die Hypothese <i>as run</i> unfalsifizierbar.

Alle 23 Claims — die Daten

Eine **kuratierte Auswahl** (inkl. zuvor übersehener Claim-Klassen), **keine** gemessene vollständige Claim-Abdeckung des Muse-Textes. Je Zeile auditierbar in `claims.jsonl` / `evidence.jsonl`. Spalte „Evidenz“ = Provenienzart der tatsächlich verfügbaren Quelle.

ID	Typ	Domäne	Urteil	Evidenz
MET-01	methodological	experiment methodology	contradicted	primär
MET-02	methodological	experiment methodology	partially_supported	primär
MET-03	methodological	experiment methodology	unverifiable	keine
VAL-01	claim about validator	legal philosophy	source_domain_mismatch	nur semantisch
VAL-02	claim about validator	experiment methodology	citation_mismatch	primär
VAL-03	claim about validator	experiment methodology	supported	primär
EB-01	claim about epistemic boundary	ml epistemology	interpretation	keine
EB-02	claim about epistemic boundary	ml epistemology	unsupported	sekundär
DEF-01	definition	legal philosophy	interpretation	keine
DEF-02	definition	legal philosophy	interpretation	keine
ATTR-01	author attribution	legal philosophy	unverifiable	keine
ATTR-02	author attribution	legal philosophy	unverifiable	keine
QUOTE-01	direct quote	legal philosophy	unverifiable	keine
QUOTE-02	direct quote	legal philosophy	unverifiable	keine
FACT-01	historical fact	legal philosophy	unverifiable	keine
HEUR-01	heuristic model	legal philosophy	heuristic_proposal	keine
HEUR-02	heuristic model	legal philosophy	heuristic_proposal	keine
HEUR-03	heuristic model	legal philosophy	heuristic_proposal	keine
THEO-01	theoretical interpretation	economics	interpretation	keine
EMP-01	empirical	positive law	unverifiable	keine
FACT-02	juristic fact	positive law	unverifiable	keine
FACT-03	historical fact	technology history	unverifiable	keine
NORM-01	normative	legal philosophy	normative_claim	keine

MarCognition vs. DESi — was anders ist

Kein Werbetext: DESi verhindert Fehler nicht, es macht die Stelle sichtbar, an der ein Fehler, eine Auslassung oder ein unzulässiger Schluss entsteht.

Dimension	MarCognition (Skeptical Agent)	DESi
Claim-Abdeckung	5 allgemeine Claims	23 kuratierte, typisierte Claims (inkl. übersehener Klassen); keine gemessene Vollständigkeit
Quellenpassung	keine (PubMed ↔ Recht)	source_domain_gate → Mismatch statt VERIFIED
Konkrete Provenienz	„das PubMed-Dokument“	exakter Anker (doc:Zeile) oder none
Widerspruchserkennung	übersieht C1, erzeugt C2	C1/C2/C3 via find_contradictions
Interpret./Heuristik	binär VERIFIED/FAILURE	heuristic_proposal / interpretation / normative
Unsicherheit	globaler Fließtext	pro Claim verdict + uncertainty + strength
Falsifizierbarkeit	keine Bedingung	benennt support/weaken/refute + fehlende Falsifizier
Auditierbarkeit	konkatenierter Freitext	jsonl je Zeile + optional Hash-Ledger
Evaluator-Selbstprüfung	keine; Fehler = Bestätigung	Report ist selbst Prüfobjekt (VAL-01..03)

Kernbefund

Der Demonstrationsfall ist nicht, dass Muse Spark Fehler macht. Er ist: die behauptete Validierung **bestätigt allgemeine juristische Aussagen mit ungeeigneten, intransparenten Quellen** (PubMed für Rechtsphilosophie, ohne Titel/Passage), **übersieht einen direkten Widerspruch im Versuchsaufbau (C1)** und **deutet das eigene Versagen als Bestätigung der Theorie** (Selbstabdichtung, ohne Falsifikationsbedingung).

Grenzen von DESi (ehrlich)

DESi ist nicht unfehlbar: die Claim-Fixierung ist eine kuratierte Auswahl (kein Auto-Extraktor), **keine gemessene vollständige Abdeckung** des Muse-Textes; die Rechtsphilosophie wird hier *nicht* inhaltlich adjudiziert (viele Claims enden bewusst auf „unverifiable“); source_domain_gate und die Selbstabdichtungs-Analyse sind kleine, allgemeine Erweiterungen. MarCognition's eigenes README/Boundary-Dokument sind vorsichtiger als der Forumsschluss — die Überdehnung liegt im Schluss, nicht in der gehedgten Hypothese. Fairnesshalber (R5): MarCognition's Ansatz hat echte Stärken — Claim-Zerlegung, Multi-Source-Retrieval, ein expliziter skeptischer Pass; der Fehler liegt in Gating/Provenienz, nicht in der Idee.

Teil II — Doktores-Audit (adversarial)

Vier quell-verankerte Prüfer (Provenienz, Methodik, Logik, Fairness) griffen die DESi-Analyse an — deterministisch, offline, kein LLM. Das Ergebnis ist gemischt: die meisten Befunde hielten stand, einige wurden eingeschränkt, C2/C3 als NICHT-Widersprüche bestätigt, Dissens bleibt erhalten.

Dieses Attest bestätigt NICHT die Wahrheit der juristischen Aussagen. Es bewertet nur Methode, Provenienz, Konsistenz und Reichweite der DESi-Fallstudie.

23	23	0	3
Claims geprüft	überlebt (uphold / +Auflage)	Verdikte umgestoßen	Befunde mit Dissens

Die drei Konflikte unter adversarialer Prüfung

C1	gehalten — logischer Widerspruch	Prompt ↔ Methode; beide nicht zugleich wahr (kleiner Prompt-Provenienz-Vorbehalt, R1)	✓
C2	reklassifiziert → Pipeline-Inkonsistenz	VERIFIED und „keine Zitate“ können koexistieren; kein logischer Widerspruch	→
C3	reklassifiziert → unbelegte Unabhängigkeit	ein LLM-Call widerlegt Unabhängigkeit nicht; sie ist nur auf keiner Achse dokumentiert	→

Attest — zwölf Dimensionen, getrennt bewertet (kein Gütesiegel)

Dimension	Rating
Reproduzierbarkeit	bestanden
Provenienz	bestanden
Claim-Ableitung	mit Auflagen
Claim-Abdeckung	mit Auflagen
Quellenpassung	mit Auflagen
Urteilslogik	bestanden
Widerspruchsklassifikation	mit Auflagen
Falsifizierbarkeit	bestanden
Fairness ggü. MarCognity	mit Auflagen
DESi-Überdehnung	mit Auflagen
Auditierbarkeit	bestanden
Offene Einwände	n/a

Gesamtattest: **passed_with_qualifications**. Die meisten Befunde hielten, weil das Artefakt schon straff war; die Schärfe des Audits liegt in den Reklassifikationen (C2/C3) und den Auflagen (R1/R2/R4/R5), nicht in einem Stempel.

Offene Fragen (fehlende Originaldaten)

- Der Live-HF-Thread und der volle MarCognity-Repo-Baum wurden nicht neu abgerufen — nur ihr wiedergegebener Inhalt ist verankert.
- Der tatsächlich abgerufene „PubMed“-Text ist unbekannt; der Domänen-Mismatch bleibt wahrscheinlich, nicht sicher.
- Muse Sparks Version / Parameter sind unbekannt; die Reproduzierbarkeit des zugrunde liegenden Versuchs ist nicht bewertbar.
- Die 23 Claims sind keine gemessene Abdeckung; die wahre Claim-Abdeckung des Muse-Textes ist unbekannt.