

Epistemische Fallstudie — Befunde mit Daten


Die „epistemische Validierung“ eines Muse-Spark-1.1-Textes durch MarCognition-AI, analysiert mit DESi

Quelle: Hugging-Face-Beitrag „*Epistemic Stress Test — Muse Spark 1.1 validated by MarCognition-AI*“ (User elly99, 2026-07-10; Zenodo 10.5281/zenodo.20509721) und github.com/elly99-AI/MarCognition-AI. Regeneriert offline & deterministisch mit `python -m desi.case_studies.marcognition_muse_spark`. Jede Zahl unten stammt aus `summary.json` / `claims.jsonl` / `evidence.jsonl`.

23 atomare Claims typisiert & verankert	4/23 Claims mit domänen- zulässiger Evidenz	3 strukturelle Konflikte (1 logischer Widerspruch)	ja selbstabdeichender Schluss; Falsifier: nein
--	--	---	---

Verteilung der Urteile (23 Claims)

Keine binären VERIFIED/FAILURE-Stempel: Heuristiken, Interpretationen und normative Aussagen bekommen eigene Kategorien; „unverifiable“ ist ein erstklassiges Urteil, keine Notlösung.



Evidenzstärke — wo konkrete Belege fehlen



18 von 23 Claims haben gar keine konkrete Evidenzpassage — der Validator nannte durchweg „das PubMed-Dokument“ ohne Titel oder Fundstelle. (Audit R4: diese Zahlen beschreiben die bereitgestellte Evidenz über 23 kuratierte Claims, keine gemessene Fundierung des Muse-Textes.)

Drei strukturelle Konflikte

Gefunden von DESis eigenem Detektor `desi.self_audit.contradictions.find_contradictions` als Schlüssel/Wert-Inkonsistenzen — nicht von Prosa behauptet. Nicht jeder ist ein logischer Widerspruch; die „Art“ hält die Stärke fest.

C1 — Logischer Widerspruch: Prompt ↔ Methode

Die Methode (muse:L206): „No epistemic instructions (verification, sources, stages)“. Der abgedruckte Prompt verlangt ≥5 Quellen mit Direktzitaten (L56–58), eine Zitationskonsistenzprüfung (L64) und sechs benannte Phasen (L29–47). Ein echter Widerspruch: beide Aussagen können nicht zugleich wahr sein. (Audit-Vorbehalt R1: der Prompt-Titel muse:L12 nennt „prompt used on chatgpt (taken from marcognity)“ — Herkunft leicht unklar; der Widerspruch hält auf den eigenen Angaben der Methode.)

C2 — Pipeline-Inkonsistenz: VERIFIED ohne zitierbare Evidenz

„VERIFIED“ und „No citations found“ können theoretisch beide zutreffen — kein strikter logischer Widerspruch. Der eigentliche Fehler: der Skeptical Agent behauptet Quellenunterstützung (L170–198), nennt aber keine Quelle und keine Passage (nur „das PubMed-Dokument“); der Citation Checker findet zugleich keine überprüfbaren Referenzen (L201–202) — obwohl der Text acht trägt (L154–161). Beide werden ohne Konsistenzprüfung zusammengefügt (agent_metacognition L48–66).

C3 — Unbelegte Unabhängigkeit: „independent“ ↔ keine dokumentierte Unabhängigkeit

Dass der Validator technisch ein einzelnes `llm.invoke` ist (skeptical_agent L62), widerlegt Unabhängigkeit nicht per se — ein externer LLM-Aufruf könnte formal unabhängig sein. Der Konflikt ist enger: „independent external validation“ (L208) wird behauptet, ohne dass auf irgendeiner Achse Unabhängigkeit dokumentiert wäre — organisatorisch, modellseitig oder evidenzseitig. Der Validator erhält genau die Generierungsdokumente (evaluator_prompt L24–28), ist nicht adversarial und nicht reproduzierbar spezifiziert. Behauptet, nicht etabliert — eine methodische Fehlklassifikation.

Selbstabdichtung & Falsifizierbarkeit

Würde stützen	Validator markiert Unverifizierbares → Lücke sichtbar; ODER Validator scheitert → Boundary „im Validator selbst“ (L237). Beide Ausgänge bestätigen.
Würde schwächen	Ein vorregistrierter Lauf, in dem der Validator mit domänenkorrekten Quellen Claims mit zitierten Passagen bestätigt — nicht bereitgestellt.
Würde widerlegen	Eine Kontrolle, in der die Residualfehler unter sauberem Source-Gating verschwinden (Pipeline-Defekt statt „intrinsische Architektur“) — nicht bereitgestellt.
Falsifikationsbedingung im Versuch?	Nein. Da Erfolg und Versagen beide bestätigen und kein Ausgang als widerlegend benannt ist, ist die Hypothese <i>as run</i> unfalsifizierbar.

Alle 23 Claims — die Daten

Eine **kuratierte Auswahl** (inkl. zuvor übersehener Claim-Klassen), **keine** gemessene vollständige Claim-Abdeckung des Muse-Textes. Je Zeile auditierbar in `claims.jsonl` / `evidence.jsonl`. Spalte „Evidenz“ = Provenienzart der tatsächlich verfügbaren Quelle.

ID	Typ	Domäne	Urteil	Evidenz
MET-01	methodological	experiment methodology	contradicted	primär
MET-02	methodological	experiment methodology	partially_supported	primär
MET-03	methodological	experiment methodology	unverifiable	keine
VAL-01	claim about validator	legal philosophy	source_domain_mismatch	nur semantisch
VAL-02	claim about validator	experiment methodology	citation_mismatch	primär
VAL-03	claim about validator	experiment methodology	supported	primär
EB-01	claim about epistemic boundary	ml epistemology	interpretation	keine
EB-02	claim about epistemic boundary	ml epistemology	unsupported	sekundär
DEF-01	definition	legal philosophy	interpretation	keine
DEF-02	definition	legal philosophy	interpretation	keine
ATTR-01	author attribution	legal philosophy	unverifiable	keine
ATTR-02	author attribution	legal philosophy	unverifiable	keine
QUOTE-01	direct quote	legal philosophy	unverifiable	keine
QUOTE-02	direct quote	legal philosophy	unverifiable	keine
FACT-01	historical fact	legal philosophy	unverifiable	keine
HEUR-01	heuristic model	legal philosophy	heuristic_proposal	keine
HEUR-02	heuristic model	legal philosophy	heuristic_proposal	keine
HEUR-03	heuristic model	legal philosophy	heuristic_proposal	keine
THEO-01	theoretical interpretation	economics	interpretation	keine
EMP-01	empirical	positive law	unverifiable	keine
FACT-02	juristic fact	positive law	unverifiable	keine
FACT-03	historical fact	technology history	unverifiable	keine
NORM-01	normative	legal philosophy	normative_claim	keine

MarCognition vs. DESi — was anders ist

Kein Werbetext: DESi verhindert Fehler nicht, es macht die Stelle sichtbar, an der ein Fehler, eine Auslassung oder ein unzulässiger Schluss entsteht.

Dimension	MarCognition (Skeptical Agent)	DESi
Claim-Abdeckung	5 allgemeine Claims	23 kuratierte, typisierte Claims (inkl. übersehener Klassen); keine gemessene Vollständigkeit
Quellenpassung	keine (PubMed ↔ Recht)	source_domain_gate → Mismatch statt VERIFIED
Konkrete Provenienz	„das PubMed-Dokument“	exakter Anker (doc:Zeile) oder none
Widerspruchserkennung	übersieht C1, erzeugt C2	C1/C2/C3 via find_contradictions
Interpret./Heuristik	binär VERIFIED/FAILURE	heuristic_proposal / interpretation / normative
Unsicherheit	globaler Fließtext	pro Claim verdict + uncertainty + strength
Falsifizierbarkeit	keine Bedingung	benennt support/weaken/refute + fehlende Falsifizier
Auditierbarkeit	konkatenierter Freitext	jsonl je Zeile + optional Hash-Ledger
Evaluator-Selbstprüfung	keine; Fehler = Bestätigung	Report ist selbst Prüfobjekt (VAL-01..03)

Kernbefund

Der Demonstrationsfall ist nicht, dass Muse Spark Fehler macht. Er ist: die behauptete Validierung **bestätigt allgemeine juristische Aussagen mit ungeeigneten, intransparenten Quellen** (PubMed für Rechtsphilosophie, ohne Titel/Passage), **übersieht einen direkten Widerspruch im Versuchsaufbau (C1)** und **deutet das eigene Versagen als Bestätigung der Theorie** (Selbstabdichtung, ohne Falsifikationsbedingung).

Grenzen von DESi (ehrlich)

DESi ist nicht unfehlbar: die Claim-Fixierung ist eine kuratierte Auswahl (kein Auto-Extraktor), **keine gemessene vollständige Abdeckung** des Muse-Textes; die Rechtsphilosophie wird hier *nicht* inhaltlich adjudiziert (viele Claims enden bewusst auf „unverifiable“); source_domain_gate und die Selbstabdichtungs-Analyse sind kleine, allgemeine Erweiterungen. MarCognition's eigenes README/Boundary-Dokument sind vorsichtiger als der Forumsschluss — die Überdehnung liegt im Schluss, nicht in der gehedgten Hypothese. Fairnesshalber (R5): MarCognition's Ansatz hat echte Stärken — Claim-Zerlegung, Multi-Source-Retrieval, ein expliziter skeptischer Pass; der Fehler liegt in Gating/Provenienz, nicht in der Idee.

Teil II — Doktoros regelgeleiteter Self-Audit

Ein regelgeleiteter **Self-Audit**: vier quell-verankerte Prüfer (Provenienz, Methodik, Logik, Fairness) griffen die DESi-Analyse an — deterministisch, offline, kein LLM. Die meisten Befunde hielten stand, einige wurden eingeschränkt, C2/C3 als NICHT-Widersprüche bestätigt, Dissens bleibt erhalten.

Reichweite der Unabhängigkeit: **logisch und provenance-basiert adversarial**, aber **nicht organisatorisch oder modellseitig unabhängig** — alle vier Prüfer sind feste Regeln aus demselben Repository. Ein sauberer deterministischer Gegencheck, KEINE unabhängige Replikation.

Dieses Attest bestätigt NICHT die Wahrheit der juristischen Aussagen. Es bewertet nur Methode, Provenienz, Konsistenz und Reichweite der DESi-Fallstudie.

23	0	2	4
Claims geprüft	Verdikte von diesem Audit umgestoßen	Konflikte reklassifiziert	Formulierungs-Revisionen

Transparente Bilanz über den gesamten Prüfprozess

- 23 Claims geprüft
- 22 unverändert oder mit Auflage bestätigt
- 1 Claim-Verdikt revidiert (MET-02: contradicted → partially_supported; im Betreiber-Review vor diesem Audit, hier bestätigt)
- 2 Konfliktklassifikationen revidiert (C2 → Pipeline-Inkonsistenz, C3 → unbelegte Unabhängigkeit)
- 4 Formulierungs-Revisionen durch diesen Audit (R1/R2/R4/R5)
- 0 Claims vollständig verworfen

Die drei Konflikte unter adversarialer Prüfung

C1	gehalten — logischer Widerspruch	Prompt ↔ Methode; beide nicht zugleich wahr (kleiner Prompt-Provenienz-Vorbehalt, R1)	✓
C2	reklassifiziert → Pipeline-Inkonsistenz	VERIFIED und „keine Zitate“ können koexistieren; kein logischer Widerspruch	→
C3	reklassifiziert → unbelegte Unabhängigkeit	ein LLM-Call widerlegt Unabhängigkeit nicht; sie ist nur auf keiner Achse dokumentiert	→

Attest — zwölf Dimensionen, getrennt bewertet (kein Gütesiegel)

Dimension	Rating
Reproduzierbarkeit	bestanden
Provenienz	bestanden
Claim-Ableitung	mit Auflagen
Claim-Abdeckung	mit Auflagen
Quellenpassung	mit Auflagen
Urteilslogik	bestanden
Widerspruchsklassifikation	mit Auflagen
Falsifizierbarkeit	bestanden
Fairness ggü. MarCognity	mit Auflagen
DESi-Überdehnung	mit Auflagen
Auditierbarkeit	bestanden
Offene Einwände	n/a

Gesamtattest: **passed_with_qualifications**. Die meisten Befunde hielten, weil das Artefakt schon straff war; die Schärfe des Audits liegt in den Reklassifikationen (C2/C3) und den Auflagen (R1/R2/R4/R5), nicht in einem Stempel.

Offene Fragen (fehlende Originaldaten)

- Der Live-HF-Thread und der volle MarCognition-Repo-Baum wurden nicht neu abgerufen — nur ihr wiedergegebener Inhalt ist verankert.
- Der tatsächlich abgerufene „PubMed“-Text ist unbekannt; der Domänen-Mismatch bleibt wahrscheinlich, nicht sicher.
- Muse Sparks Version / Parameter sind unbekannt; die Reproduzierbarkeit des zugrunde liegenden Versuchs ist nicht bewertbar.
- Die 23 Claims sind keine gemessene Abdeckung; die wahre Claim-Abdeckung des Muse-Textes ist unbekannt.